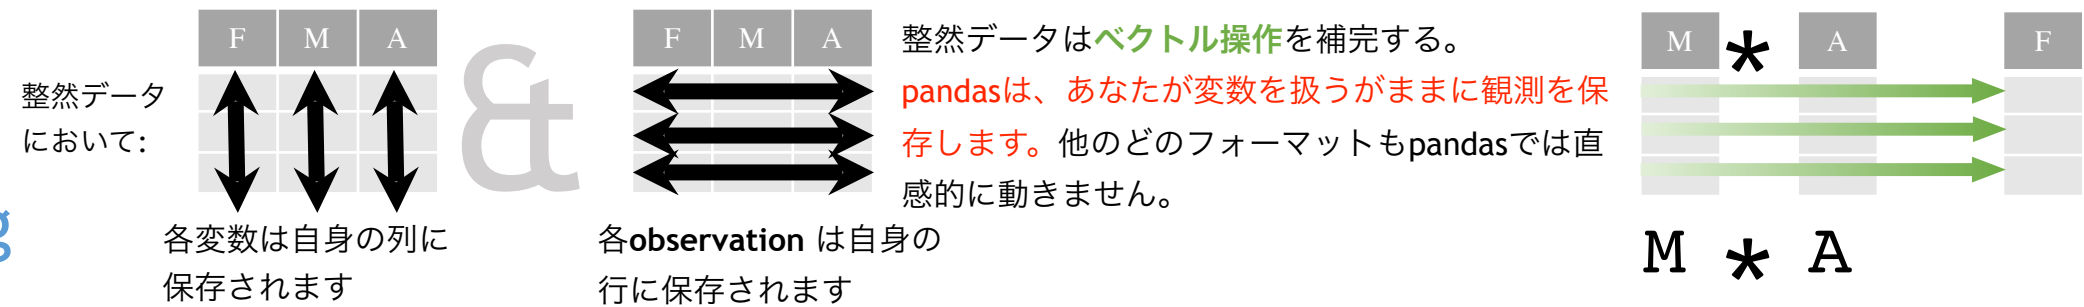


Data Wrangling with pandas Cheat Sheet

<http://pandas.pydata.org>

整然データ (Tidy Data) - pandasにおける議論の基盤



文法 - DataFrameの作成

```
df = pd.DataFrame(  
    {"a": [4, 5, 6],  
     "b": [7, 8, 9],  
     "c": [10, 11, 12]},  
    index=[1, 2, 3])  
各column(列)の値をセットする
```

```
df = pd.DataFrame(  
    [[4, 7, 10],  
     [5, 8, 11],  
     [6, 9, 12]],  
    index=[1, 2, 3],  
    columns=['a', 'b', 'c'])  
各row(行)の値をセットする
```

		a	b	c
n	v			
d	1	4	7	10
	2	5	8	11
e	2	6	9	12

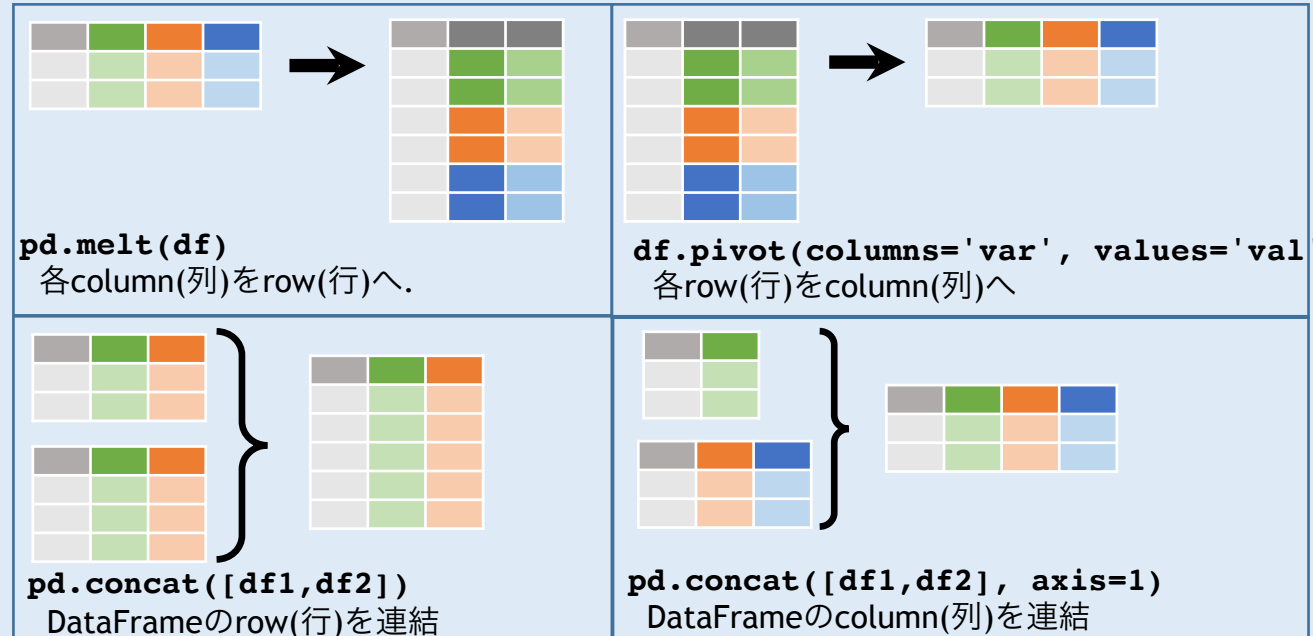
```
df = pd.DataFrame(  
    {"a": [4, 5, 6],  
     "b": [7, 8, 9],  
     "c": [10, 11, 12]},  
    index = pd.MultiIndex.from_tuples(  
        [('d', 1), ('d', 2), ('e', 2)],  
        names=['n', 'v']))  
MultiIndexでDataframeを作成する
```

メソッドチェーン

pandasにおける多くのメソッドはDataframeを返します。そのため、メソッドの返り値にそのまま別のメソッドを適用するメソッドチェーンが便利に使えます。この手法はコードの可動性を大いにあげます。

```
df = (pd.melt(df)  
      .rename(columns={'variable':  
                      'var',  
                      'value': 'val'})  
      .query('val >= 200'))
```

データの整形(Reshaping Data) - データセットのレイアウト変更



```
df.sort_values('mpg')  
column(列)の値を使ってrow(行)をソート(昇順)
```

```
df.sort_values('mpg', ascending=False)  
column(列)の値を使ってrow(行)をソート(降順)
```


```
df.rename(columns = {'y': 'year'})  
DataFrameのcolumn(列)名を変更
```

```
df.sort_index()  
DataFrameのindexを使ってソート
```

```
df.reset_index()  
DataFrameのindexをリセット
```

```
df.drop(columns=['Length', 'Height'])  
指定した長さのcolumn(列)を削除
```

Observations(行)の一部を抜き出し



```
df[df.Length > 7]  
与えられた条件に合った行を抜き出す
```

```
df.drop_duplicates()  
値の重複するrow(行)を除外
```

```
df.head(n)  
最初のn行を取得
```

```
df.tail(n)  
最後のn行を取得
```

```
df.sample(frac=0.5)  
行を[frac]ランダムで取得  
※fracは割合(1 = 100%)
```

```
df.sample(n=10)  
n行をランダムで取得
```

```
df.iloc[10:20]  
指定位置の行を取得
```

```
df.nlargest(n, 'value')  
'value'列のn行を降順で取得
```

```
df.nsmallest(n, 'value')  
'value'列のn行を昇順で取得
```

変数(列)からの一部取得



```
df[['width', 'length', 'species']]  
複数column(列)を列名を指定して取得
```

```
df['width'] or df.width  
1つのcolumn(列)を列名を指定して取得
```

```
df.filter(regex='regex')  
column(列)を正規表現でフィルタリング
```

regex (正規表現) の例

'\.'	ピリオド '.' を含む文字列にマッチ
'Length\$'	末尾に 'Length' のある文字列にマッチ
'^Sepal'	冒頭に 'Sepal' のある文字列にマッチ
'^x[1-5]\$'	'x' で始まり且つ末尾が 1-5 のいずれかである文字列にマッチ
'^(?!Species\$).*'	'Species' 以外の文字列とマッチ

```
df.loc[:, 'x2': 'x4']  
x2 から x4 までの全てのcolumn(列)を取得
```

```
df.iloc[:, [1, 2, 5]]  
1, 2, 5 番目 (index が 5 番目) の列を取得 (index は 0 から数える)
```

```
df.loc[df['a'] > 10, ['a', 'c']]  
与えられた条件に合ったrow(行)で且つ指定されたcolumn(列)を取得
```

データの要約

df['w'].value_counts()
変数の出現回数をカウント

len(df)
DataFrameの行数を出力

df['w'].nunique()
ユニークな値をカウントして出力

df.describe()
Basic descriptive statistics for each column (or GroupBy)



pandasは様々な種類のpandasオブジェクト(DataFrame columns, Series, GroupBy, Expanding and Rolling(下記参照))を操作する
summary functions(要約関数)を提供し、各グループに対して1つの値を返します。DataFrameに適用された場合、結果は各column(列)にSeries型で返されます。例:

sum()
各オブジェクトの値を合計

min()
各オブジェクトの最小値を取得

count()
各オブジェクトのNA/null以外の値をカウント

max()
各オブジェクトの最大値を取得

median()
各オブジェクトの中央値を取得

mean()
各オブジェクトの平均を取得


quantile([0.25, 0.75])
各オブジェクトの分位値を取得

var()
各オブジェクトの分散値を取得

apply(function)
各オブジェクトに適用

std()
各オブジェクトの標準偏差を取得

データのグループ化



df.groupby(by="col")
“col”列の値でグループ化したGroupByオブジェクトを返す

df.groupby(level="ind")
インデックスレベル“ind”でグループ化したGroupByオブジェクトを返す

上述した要約関数(summary function)は全てgroupにも適用可能です。その他GroupByの関数:

size()
各グループの長さ

agg(function)
関数を使ってグループを集計

shift(1)
1行ずつ後ろにずらした値をコピー

rank(method='dense')
ランク付け(同数はギャップなしで計算)

rank(method='min')
ランク付け(同数は小さい値にする)

rank(pct=True)
[0~1]の値でランク付け

rank(method='first')
ランク付け。同数の場合indexが小さい方が上位

shift(-1)
1行ずつ前にずらした値をコピー

cumsum()
累積和

cummax()
累積最大値

cummin()
累積最小値

cumprod()
累積積

window関数

df.expanding()
要約関数を累積的に適用可能にした Expanding オブジェクトを返す


df.rolling(n)
長さnのwindowに要約関数を適用可能にしたRollingオブジェクトを返す

欠損データを扱う

df.dropna()
NA/nullを含むrow(行)を除外する

df.fillna(value)
NA/nullをvalueに置換

新しいColumn(列)の作成



df.assign(Area=lambda df: df.Length*df.Height)
1つ以上の新たなcolumn(列)を計算して追加

df['Volume'] = df.Length*df.Height*df.Depth
新たなcolumn(列)を1つ追加

pd.qcut(df.col, n, labels=False)
column(列)の値をn分割



pandasはDataFrameの全てのcolumn(列)または選択された1列(Series型)を操作できる**vector functions(ベクトル関数)**を提供します。それらの関数は各列(column)に対してベクトル値を返します。また、各Seriesには1つのSeriesを返します。例:

max(axis=1)
要素ごとの最大値を取得

clip(lower=-10, upper=10)
下限を-10,上限を10に設定してトリミング


min(axis=1)
要素ごとの最大値を取得

abs()
絶対値を取得


下記関数もgroupに対して適用できます。この場合、関数はグループ毎に適用され、返されるベクトル値は元のDataFrameとpな時長さになる。

プロット(描画)

df.plot.hist()
各列のヒストグラムを描画



df.plot.scatter(x='w', y='h')
散布図を描画



データの結合

adf

x1	x2
A	1
B	2
C	3

+

bdf

x1	x3
A	T
B	F
D	T

=

標準的な結合

x1	x2	x3
A	1	T
B	2	F
C	3	NaN

pd.merge(adf, bdf, how='left', on='x1')
ddfをadfのマッチする行へ結合

x1	x2	x3
A	1.0	T
B	2.0	F
D	NaN	T

pd.merge(adf, bdf, how='right', on='x1')
adfをbdfのマッチする行へ結合

x1	x2	x3
A	1	T
B	2	F

pd.merge(adf, bdf, how='inner', on='x1')
adfとbdfを双方にある行のみ残して結合

x1	x2	x3
A	1	T
B	2	F
C	3	NaN
D	NaN	T

pd.merge(adf, bdf, how='outer', on='x1')
全ての値と行を残して結合

フィルタリング結合

x1	x2
A	1
B	2

adf[adf.x1.isin(bdf.x1)]
adfの中でbdfにマッチする行

x1	x2
C	3

adf[~adf.x1.isin(bdf.x1)]
adfの中でbdfにマッチしない行

ydf

x1	x2
A	1
B	2
C	3

+

zdf

x1	x2
B	2
C	3
D	4

=

集合ライクな結合

x1	x2
B	2
C	3

pd.merge(ydf, zdf)
ydfとzdf両方にある行

x1	x2
A	1
B	2
C	3
D	4

pd.merge(ydf, zdf, how='outer')
ydfとzdfの両方もしくは片方にある行

x1	x2
A	1

pd.merge(ydf, zdf, how='outer', indicator=True)
.query('_merge == "left_only"')
.drop(columns=['_merge'])
ydfにはあるがzdfにはない行